

# Métodos Numéricos II 2022

Lista 03

29.septiembre.2022

1. Implementar los siguientes métodos de descenso gradiente (naïve = tamaño de paso  $\alpha$  constante):

- descenso gradiente naïve con dirección de descenso aleatoria,
- descenso máximo naïve (*steepest descent*).
- descenso gradiente con búsqueda en línea *Backtracking* ( $\alpha$  no constante).
- descenso gradiente con dirección de Newton (Hessiano exacto).
- descenso gradiente con dirección de Newton, con Hessiano aproximado.

En cada uno de los métodos, su función debe recibir los siguientes argumentos: la función objetivo  $f$ , el gradiente de la función objetivo  $df$ ,  $d^2f$  (cuando sea necesario), un punto inicial  $\mathbf{x}_0 \in \mathbb{R}^n$ , el tamaño de paso  $\alpha > 0$ , el número máximo de iteraciones *maxIter*, la tolerancia  $\varepsilon$ , así como un criterio de paro.

En los casos que se use Backtracking,  $\alpha = \alpha_0$  corresponde al inicio de la búsqueda lineal, y se debe incorporar un parámetro  $\rho > 0$  de tasa de decaimiento. En el caso del Backtracking, usted decide si usar las condiciones de Wolfe o de Goldstein.

Como resultado, sus algoritmos deben devolver: la mejor solución encontrada *best x* (la última de las aproximaciones calculadas); la secuencia de iteraciones  $\mathbf{x}_k$ ; la secuencia de valores  $f(\mathbf{x}_k)$ ; la secuencia de errores en cada paso (según el error de su criterio de paro).

Además, es deseable indicar el número de iteraciones efectuadas por el algoritmo, y si se obtuvo o no convergencia del método.

2. Testar los algoritmos del Ejercicio 1 con las siguientes funciones:

a) La función de Rosembrock 2-dimensional  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ , dada por

$$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2.$$

Punto inicial:  $\mathbf{x}_0 = (-1.2, 1)^T$ . Óptimo:  $\mathbf{x}^* = (1, 1)^T$ ,  $f(\mathbf{x}^*) = 0$ .

b) La función de Wood  $f : \mathbb{R}^4 \rightarrow \mathbb{R}$ , dada por

$$f(x, y) = 100(x_1^2 - x_2)^2 + (x_1 - 1)^2 + (x_3 - 1)^2 + 90(x_3^2 - x_4).$$

Punto inicial:  $\mathbf{x}_0 = (-3, 1, -3, 1)^T$ . Óptimo:  $\mathbf{x}^* = (1, 1, 1, 1)^T$ ,  $f(\mathbf{x}^*) = 0$ .

c) La función de Rosembrock 100-dimensional  $f : \mathbb{R}^{100} \rightarrow \mathbb{R}$ , dada por

$$f(\mathbf{x}) = \sum_{i=1}^{99} [100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2].$$

Punto inicial:  $\mathbf{x}_0 = (-1.2, 1, 1, \dots, 1, -1.2, 1)^T$ . Óptimo:  $\mathbf{x}^* = (1, 1, \dots, 1)^T$ ,  $f(\mathbf{x}^*) = 0$ .

En cada uno de los casos, hallar un tamaño de paso  $\alpha$  que garantice la convergencia de los métodos, y elabore una tabla con las primeras 3 y las últimas 3 aproximaciones  $\mathbf{x}_k$  obtenidas.

Para este tamaño de paso, comparar:

- la solución aproximada obtenida
- el error de aproximación
- la norma del gradiente en la solución

Elabore gráficas que muestren el error de aproximación, en función del número de iteración, y muestre la comparación de la evolución de la convergencia en sus tres métodos. A partir de estas gráficas, discuta cuál de los métodos es más efectivo, en cada caso.

3. Construya una función “suma de gaussianas” 2-dimensional, en la forma

$$f(\mathbf{x}) = - \sum_{i=1}^k \exp \left( - \frac{1}{2\sigma} \|\mathbf{x} - \mathbf{x}_k\|_2^2 \right),$$

donde  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  son puntos en el rectángulo  $[0, 8] \times [0, 8]$  elegidos de forma aleatoria (distribución uniforme). Use  $k = 8$ , Aquí,  $\sigma > 0$  es un parámetro de escala definido por el usuario (que indica qué tan suave se desea la función).

Aplique varias veces el método de descenso gradiente a la función  $f$ , con inicializaciones  $\mathbf{x}_0$  distintas, de forma que se puedan obtener los diferentes mínimos locales de la función.

Muestre visualizaciones de diferentes secuencias de aproximaciones  $\{\mathbf{x}_k\}$  convergiendo a cada uno de los mínimos locales de su función.

